ResNet50 기반 폐암 CT 분류에서 Block Encryption · Gaussian Blur의 프라이버시-정확도 트레이드오프 분석

곽윤석*,김남기**

Privacy-Accuracy Trade-off Analysis of Block Encryption and Gaussian Blur in ResNet50-based Lung Cancer CT Classification

Yunsuk Kwak*, Namgi Kim**

본 연구는 2026년 경기대학교 대학원 연구원장학생 장학금 지원에 의하여 수행되었음. 이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원-학·석사연계ICT핵심인재양성사업의 지원을 받아 수행된 연구임(ITTP-2024-00436954). 또한 이 논문은 2024년도 정부(교육부)의 재원으로 한국연구재단의 지원을 받아 수행된 기초연구사업임(No. RS-2020-NR049579)

요 약

폐 CT 영상 1,097장(양성 120 · 악성 561 · 정상 416)에 Block Encryption과 Gaussian Blur를 각각 10단계 적용하고, 두 기법의 조합을 포함한 총 120개 조건을 구성하였다. 각 조건에서 ResNet50을 7-Fold 교차검증과 TTA 20회로 학습하여 정확도를 측정하고, 개인정보 보호 수준은 MS-SSIM 기반 Privacy Score(0~50)로 정량화하였다. 원본 영상의 정확도는 98.17%(ROC-AUC 0.982)였다. Gaussian Blur는 σ=256에서 Privacy Score 34.62를 기록했으나 정확도는 51.38%로 감소하였다. 반면 Block Encryption은 256×256에서 Privacy Score 49.65를 확보하면서도 정확도 98.17%(ROC-AUC 0.992)를 유지하였다. 평균 Privacy Score 역시 Block Encryption이 43.47로 Gaussian Blur의 16.05보다 2.7배 높아, 정확도와 개인정보 보호의 균형에서 더 우수함을 확인하였다.

Abstract

This study applied Block Encryption and Gaussian Blur at 10 levels each, individually and in combination, to 1,097 lung CT images and trained ResNet50 with 7-fold cross-validation and test-time augmentation across 120 conditions, quantifying privacy protection using an MS-SSIM-based Privacy Score (0-50). Original images achieved 98.17% accuracy (ROC-AUC 0.982); Gaussian Blur reached a Privacy Score of 34.62 at σ=256, but accuracy dropped to 51.38%, whereas Block Encryption at 256×256 achieved a Privacy Score of 49.65 while maintaining 98.17% accuracy (ROC-AUC 0.992). The mean Privacy Score was 2.7 times higher for Block Encryption (43.47) than for Gaussian Blur (16.05), demonstrating a superior accuracy-privacy trade-off.

Key words

lung computed tomography, block encryption, gaussian blur, privacy protection, resnet50

* 경기대학교
- ORCID: https://orcid.org/0009-0004-0207-4000
** 경기대학교 교수(교신저자)
- ORCID: http://orcid.org/0000-0002-0077-6576

· Received: 00 17, 2024, Revised: 00 20, 2024, Accepted: 00 15, 2025

· Corresponding Author: Namgi Kim
Kyonggi University, Suwon, Korea
Tel.: Email: ngkim@kyonggi.ac.kr

I. 서 론

1.1 연구 배경 및 필요성

폐암은 2022년 기준 전 세계에서 약 248만 건의 신규 발생과 182만 건의 사망이 보고되어 전체 암종 중 발생률 1위(12.4%), 사망률 1위(18.7%)를 차지하는 대표적인 고위험 질환이다[1]. 조기 진단은 치료 성공률을 좌우하는 핵심 요인이며, 흉부 CT(Computed Tomography) 영상은 병변의 위치와 형태를 확인할 수 있는 주요 진단 자료로 활용되고 있다. 최근에는 의료 데이터의 축적과 딥러닝 기술의 발전에 힘입어 CT 영상을 자동으로 분석·분류하는 연구가 활발히 이루어지고 있으며, 특히 ResNet과 같은 잔차 학습(residual learning) 기반 CNN 구조는 의료 영상의 미세한 병변 특징을 효과적으로 학습하여 폐암 분류를 포함한 다양한 의료 영상 분석 분야에서 높은 성능을 보이고 있다[2].

한편 폐 CT 영상은 환자의 신체 구조와 병변 정보를 직접 포함하는 민감한 개인 의료정보로, 인공지능 모델 학습을 위한 데이터 구축·공유·클라우드 활용 과정에서 개인정보 노출 위험이 상존한다. 이에 따라 의료영상 비식별화(de-identification)에 관한 국제적 논의가 활발히 이루어지고 있으며, 대표적으로 MIDI(Medical Image De-Identification) Task Group은 의료영상 비식별화의 모범 사례와 권고안을 제시한 바 있다[3]. 실무적으로 가장 널리 쓰이는 비식별화 기법은 Gaussian Blur와 Block Encryption(블록 스크램블링)이다. Gaussian Blur는 영상 전역에 평활화 필터를 적용해 세부 구조를 흐리게 하는 방식이며, Block Encryption은 영상을 일정 크기의 블록으로 분할한 뒤 블록 단위로 재배열하여 전역 구조를 직접 식별할 수 없게 만드는 방식이다. 그러나 두 기법 모두 비식별화 강도가 높아질수록 영상 내 진단에 필요한 정보 자체가 함께 손실되므로, 개인정보 보호 수준과 인공지능 모델의 진단 성능은 근본적으로 상충(trade-off) 관계에 있다.

1.2 연구 목적 및 기여

의료영상 비식별화에 관한 기존 연구들은 Gaussian Blur와 Block Encryption(블록 스크램블링)을 대체로 독립적인 기법으로 다루어 왔다(2.1절). Chuman과 Kiya[7]와 Sirichotedumrong 등[8]은 블록 스크램블링 기반 암호화 영상의 분류 성능을 검증하였고, McPherson 등[6]은 Gaussian Blur의 역복원 취약성을 지적하였으나, (1) 두 기법을 순차적으로 조합했을 때의 상호작용 효과를 다룬 연구는 찾아보기 어려우며, (2) 개인정보 보호 수준은 대체로 변환 강도(블록 크기, σ 값)로만 서술될 뿐 정량적 지표로 측정되지 않았고, (3) 단일 학습 결과에 기반해 결과의 통계적 신뢰도를 검증한 사례도 드물다.

첫째, 분류 모델로 실무에서 널리 쓰이는 잔차 학습(residual learning) 기반 CNN인 ResNet50을 채택하여 트레이드오프를 검증한다. 둘째, Block Encryption(블록 크기 10단계)과 Gaussian Blur(σ 10단계)를 단독 적용뿐 아니라 두 기법을 순차 결합한 100가지 조합까지 포함하여 총 120개 비식별화 조건에서 성능을 평가함으로써, 선행연구가 다루지 못한 두 기법의 상호작용 효과를 규명한다. 셋째, 단일 스케일 SSIM이 지역적 평활화에 둔감하다는 한계를 보완하기 위해 MS-SSIM(Multi-Scale SSIM)[4]에 기반한 Privacy Score를 도입하여, 그동안 정성적으로만 서술되던 개인정보 보호 수준을 0~50 범위의 정량 지표로 측정한다. 넷째, 7-Fold 교차검증과 Test-Time Augmentation 앙상블을 적용하여 각 조건의 분류 성능을 통계적으로 안정적으로 추정한다. 이를 통해 본 연구는 정확도와 정량화된 프라이버시 점수를 두 축으로 하는 트레이드오프 관계를 체계적으로 분석하고, 개인정보 보호와 진단 성능을 동시에 만족하는 실무적 최적 조건을 제시하는 것을 목표로 한다.

1.3 논문 구성

본 논문의 구성은 다음과 같다. 2장에서는 의료영상 비식별화 기법과 딥러닝 기반 폐암 CT 분류에 관한 선행연구를 검토하고 본 연구진의 1차 연구와의 차별점을 정리한다. 3장에서는 데이터셋, 비식별화 변환 기법, ResNet50 기반 분류 모델과 학습 전략, MS-SSIM 기반 Privacy Score, 실험 설계를

상세히 기술한다. 4장에서는 Block Encryption 단독, Gaussian Blur 단독, 두 기법의 조합에 대한 실험 결과와 Privacy Score 분석, 정확도-프라이버시 트레이드오프 분석 결과를 제시한다. 5장에서는 실험 결과를 바탕으로 두 기법의 특성을 비교하고 모델 붕괴 현상, 임상적 적용 가능성과 한계를 논의한다. 마지막으로 6장에서는 연구 결과를 종합하여 결론을 도출하고 향후 연구 방향을 제시한다.

Ⅱ. 선행 연구

2.1 의료영상 프라이버시의 정의

일반적인 프라이버시 침해 논의는 안면 인식과 같이 영상에서 특정 인물을 시각적으로 알아볼 수 있는지를 기준으로 이루어져 왔으나, 이러한 기준은 얼굴이 포함되지 않는 흉부 CT・X-ray와 같은 의료영상에는 그대로 적용하기 어렵다. 그러나 원본 의료영상이 촬영 목적(진단) 이외의 주체인 외부 클라우드 연산 자원, 제3의 연구기관 등에게 노출되는 것은, 그 영상에서 얼굴을 알아볼 수 있는지 여부와 무관하게 그 자체로 프라이버시 침해에 해당한다.

이러한 노출은 크게 세 가지 경로로 구체화된다. 첫째, DICOM 헤더와 같은 부속 메타데이터를 통한 직접적 신원 노출이다. 둘째, 영상의 해부학적 구조 자체가 개인을 특정하는 생체 정보로 기능할 수 있다는 점이다. 실제로 Packhäuser 등[20]은 흉부 X-ray 영상만으로도 딥러닝 기반 환자 재식별(patient re-identification)이 AUC 0.99 이상의 정확도로 가능함을 보임으로써, 얼굴이 없는 의료영상 역시 그 자체로 생체 인식 정보(biometric identifier)로 기능할 수 있음을 실증하였다. 셋째, 영상에 내재된 진단 소견(예: 악성 종양)이 특정 개인에게 귀속됨으로써 발생하는 민감정보 노출이다.

이에 본 연구는 의료영상 프라이버시를 “촬영된 원본 영상 또는 그로부터 추론 가능한 신원・진단 정보가, 진단이라는 본래 목적을 벗어나 의도되지 않은 주체에게 노출됨으로써 발생하는 정보 유출”로 정의한다. 이 정의에 따르면 비식별화의 목표는 안면 인식을 방지하는 것이 아니라, 영상이 유출되었을 때 (1) 원본으로 역복원되거나 (2) 개인 식별에 활용될 수 있는 구조적 단서를 제거하는 것이며, 본 연구가 3.5절에서 구조적 유사도 기반 지표를 프라이버시 정량화 수단으로 채택한 근거이기도 하다.

2.1.1 Gaussian Blur 기반 비식별화

Gaussian Blur는 얼굴이나 개인정보 영역에 평활화 필터를 적용해 세부 정보를 흐리게 만드는 가장 널리 쓰이는 비식별화 기법으로, 온라인 동영상 플랫폼의 얼굴 자동 블러 기능 등 실무에 광범위하게 적용되어 왔다. 그러나 McPherson 등[6]은 딥러닝 기반 역복원(deblurring) 공격으로 블러 처리된 얼굴 영상의 상당수를 재식별할 수 있음을 보여, Gaussian Blur가 딥러닝 공격자에 대해서는 근본적인 보안성을 제공하지 못한다는 한계를 제기하였다. 이는 Gaussian Blur가 영상의 저주파 성분(전역 밝기・명암 분포)은 비교적 온전히 보존한 채 고주파 성분(경계・텍스처)만 제거하는 방식으로 동작하기 때문이며, 본 연구에서 Gaussian Blur의 Privacy Score가 Block Encryption 대비 낮게 나타난 현상과도 맥을 같이 한다.

2.1.2 Block Encryption(스크램블링) 기반 비식별화

Block Encryption(블록 스크램블링)은 영상을 일정 크기의 블록으로 분할한 뒤 블록의 위치를 재배열하여 원본의 전역 구조를 직접 식별할 수 없게 만드는 기법이다. Chuman과 Kiya[7]는 블록 스크램블링에 랜덤 크로핑・수평 반전・그리드 마스크 등의 데이터 증강을 결합함으로써 암호화된 영상을 사용하면서도 높은 분류 정확도를 유지할 수 있는 학습 가능한(learnable) 영상 암호화 기법을 제안하였으며, 이는 블록 스크램블링이 다양한 공격에 강인하면서도 딥러닝 분류 성능 저하를 최소화할 수 있음을 시사한다. Sirichotedumrong 등[8]은 그레이스케일 기반 블록 스크램블링을 제안하여 암호화 이후에도 압축 효율과 보안성을 동시에 확보할 수

있음을 보였다. 다만 이러한 선행연구들은 주로 SNS·클라우드 환경의 일반 영상을 대상으로 하였으며, 본 연구처럼 의료 CT 영상에 블록 스크램블링을 적용하고 정량적 프라이버시 지표와 함께 분류 성능을 체계적으로 평가한 사례는 찾아보기 어렵다.

2.1.3 기타 기법(차분 프라이버시, 연합학습, 암호화 도메인 추론)

Shokri와 Shmatikov[5]는 분산 환경에서 그래디언트 정보를 공유하는 과정에서 발생할 수 있는 정보 노출을 줄이기 위해 프라이버시 보존형 딥러닝 학습 방법을 제안하였으며, 이는 딥러닝 학습 과정 자체에서 개인정보 보호를 고려하는 연구의 초기 접근으로 볼 수 있다. Dwork와 Roth[9]가 정립한 차분 프라이버시(Differential Privacy)는 개별 데이터의 포함 여부가 모델 출력에 미치는 영향을 수학적으로 제한하는 프라이버시 보호 기법으로, 학습 과정에서 그래디언트에 노이즈를 추가하는 DP-SGD가 대표적이다. Mohammadi 등[10]은 의료 딥러닝 분야에서 차분 프라이버시를 적용한 74편의 선행연구를 체계적으로 검토한 결과, 중간 수준의 프라이버시 예산에서는 임상적으로 허용 가능한 성능을 유지할 수 있지만, 강한 프라이버시 보장을 요구할수록 정확도가 크게 저하되는 경향을 확인하였다. 이러한 결과는 적용 방식에는 차이가 있으나, 개인정보 보호 수준이 높아질수록 분류 정확도가 저하되는 본 연구의 결과와 유사한 경향을 보인다. 또한 원본 데이터를 기관 외부로 전송하지 않고 다기관 협업 학습을 수행하는 연합학습(Federated Learning)과 암호화된 상태에서 데이터를 처리하는 동형암호(Homomorphic Encryption) 기반 추론 등의 대안적 방법도 연구되고 있다. 그러나 이러한 방법들은 일반적으로 높은 시스템 복잡도와 연산 비용을 요구하므로 실시간 임상 환경에 적용하는 데에는 한계가 있다.

2.2 딥러닝 기반 폐암 CT 영상 분류 연구

본 연구에서 사용한 데이터셋은 이라크의 두 전문병원에서 수집된 IQ-OTH/NCCD(Iraq-Oncology Teaching Hospital/National Center for Cancer Diseases) 폐암 CT 데이터셋으로[11], 양성(Benign) 120장, 악성(Malignant) 561장, 정상(Normal) 416장, 총 1,097장의 CT 영상으로 구성된다. 공개 이후 다수의 폐암 CT 분류 연구에서 벤치마크로 활용되고 있으며, 예를 들어 Choudhury 등[12]은 본 연구와 동일한 1,097장의 원본 영상에 대해 Custom CNN·VGG16·ResNet50·InceptionV3를 비교하여 최고 98.7%의 검증 정확도를 보고하였다. 이는 원본(비식별화 이전) 영상에 대한 ResNet 계열 모델의 분류 성능이 본 연구의 원본 조건 결과(98.17%)와 유사한 수준임을 뒷받침한다. 그 밖에도 어텐션 메커니즘, DenseNet, Vision Transformer 결합 구조 등을 활용해 양성·악성·정상 3-class 분류 성능을 개선하려는 연구가 지속적으로 보고되고 있다. 그러나 이들 연구는 대부분 원본 영상 자체의 분류 성능 향상에 초점을 두었을 뿐, 프라이버시 보존 변환이 적용된 상태에서의 성능 변화는 다루지 않았다는 점에서 본 연구와 차별화된다.

Ⅲ. 연구 방법

3.1 데이터셋

3.1.1 데이터 구성 및 클래스 분포

본 연구는 IQ-OTH/NCCD 폐암 CT 데이터셋[11]을 사용하였다. 이 데이터셋은 이라크 소재 두 전문병원(Iraq-Oncology Teaching Hospital, National Center for Cancer Diseases)에서 수집된 흉부 CT 영상으로, 양성(Benign) 120장, 악성(Malignant) 561장, 정상(Normal) 416장, 총 1,097장으로 구성되어 있다. 모든 영상은 512×512 픽셀로 리사이즈하여 사용하였다.

클래스별 비율은 사전에 Stratified 방식으로 학습/평가에 사용할 원본 파일을 확정한 뒤, 클래스별 10%를 테스트셋으로 분리하고 나머지 90%(kfold_data)만을 학습·검증에 사용하였다. 테스트셋 크기는 클래스별 파일 수에 test_ratio=0.10을 곱한 뒤 버림

(int) 처리하는 방식으로 산정되어, Benign 12장, Malignant 56장, Normal 41장, 총 109장으로 고정되었다(반올림이 아닌 버림 처리이므로 Normal은 41.6장이 아닌 41장이 된다). 테스트셋 분리는 증강 이전 원본 파일에 대해서만 수행하였으며, 이후 매 조건·매 실험마다 테스트셋에 증강본(aug_ 접두 파일)이 포함되지 않았는지 자동 검증하는 assert 구문을 두어 데이터 누수(leakage)를 원천 차단하였다.

3.1.2 데이터 증강 및 클래스 불균형 처리

클래스 불균형(Benign 120장 vs. Malignant 561장) 문제를 완화하기 위해, kfold_data에 한해 회전(-30° ~+30°), 좌우/상하 반전(각 50% 확률), 밝기 보정(0.7~1.3배)을 적용한 오버샘플링으로 클래스별 1,000장까지 증강하였다. tf.data 파이프라인 단계에서는 추가로 좌우/상하 무작위 반전, 밝기 변화(±0.25×255), 대비 변화(0.75~1.25배), 가산 가우시안 잡음(평균 0, 표준편차 5)을 실시간 적용하였다. 배치 단위에서는 Mixup·CutMix[15][16]를 결합 적용하였으며(세부 설정은 3.4.3절 참고), 학습 시 클래스 가중치는 scikit-learn의 balanced 가중치를 기본으로 하되 Benign 클래스에 ×2.5, Normal 클래스에 ×1.3의 추가 가중치를 부여하였다.

오버샘플링(클래스별 1,000장)과 별개로, 배치 손실 계산 시에는 scikit-learn의 balanced 클래스 가중치를 기본값으로 사용하였다. 전체 샘플 수 N, 클래스 수 K=3, 클래스 c의 샘플 수 N_c에 대해:

$$w_c^{balanced} = \frac{N}{K \times N_c}, \qquad w_c = w_c^{balanced} \times m_c \qquad (1)$$

m_c는 클래스별 수동 배율로, Benign은 m=2.5, Normal은 m=1.3, Malignant는 m=1.0(배율 없음)을 적용하였다. balanced 가중치가 이미 소수 클래스(Benign 120장)에 큰 가중치를 부여함에도 추가 배율을 곱한 것은, 오버샘플링된 증강 이미지가 실제 다양성 측면에서 원본 이미지보다 정보량이 적다는 점을 감안해 소수 클래스의 손실 기여도를 한 번 더 보정하기 위함이다.

3.2 프라이버시 보존 변환 기법

3.2.1 Block Encryption

영상을 block_size×block_size 크기의 블록으로 분할한 뒤, 시드 기반 난수 순열(numpy default_rng(seed).permutation)로 블록의 위치를 재배열하는 방식이다(블록 내부 픽셀 자체는 변경하지 않음). 영상 크기가 블록 크기로 나누어떨어지지 않는 경우 reflect 패딩 후 처리하였다. 블록 크기는 512(원본, 변환 없음), 256, 128, 64, 32, 16, 8, 4, 2, 1의 10단계를 사용하였다.

3.2.2 Gaussian Blur

PIL의 GaussianBlur(radius=σ)를 그대로 적용하였으며, σ는 0(원본, 변환 없음), 1, 2, 4, 8, 16, 32, 64, 128, 256의 10단계를 사용하였다.

3.2.3 조합 적용 방식(100가지 조건)

Block Encryption을 먼저 적용한 뒤 그 결과에 Gaussian Blur를 순차 적용하는 방식으로, 10×10 = 100가지 조합을 모두 생성하였다. 원본 파일은 어떤 단계에서도 직접 수정하지 않고, 조건별로 별도 디렉터리에 결과물을 저장하였다. 이와 별도로 Block Encryption 단독 10조건, Gaussian Blur 단독 10조건을 각각 독립된 실험으로 추가 수행하여 조합 실험의 σ=0/block=512 행과 교차 검증하였다(두 독립 실행 간에는 실험별 시드가 달라 결과에 차이가 존재할 수 있으며, 이 차이는 대체로 1%p 이내이지만 σ=256과 같이 정보 파괴 강도가 가장 높은 극단 조건에서는 5%p 가까이 벌어질 수 있다).

3.3 분류 모델 아키텍처

3.3.1 ResNet50 백본

ImageNet 사전학습 가중치를 사용한 ResNet50[2]

을 백본으로 채택하였다(include_top=False, 입력 512×512×3). 1단계 학습에서는 백본을 완전히 동결(freeze)하고, 2단계 학습에서 백본 마지막 30개 레이어만 미세조정(fine-tuning) 가능하도록 해제하였다.

3.3.2 분류 헤드 구조

백본 출력에 대해 GlobalAveragePooling2D(GAP)와 GlobalMaxPooling2D(GMP)를 각각 계산한 뒤 Concatenate로 결합하고, Dense(512, L2=1e-4) → BatchNorm → ReLU → Dropout(0.35) → Dense(256, L2=1e-4) → BatchNorm → ReLU → Dropout(0.25) → Dense(3, softmax) 구조의 완전연결 헤드를 이어붙였다. 혼합정밀도(mixed_float16) 학습 안정성을 위해 최종 출력층만 float32로 강제 캐스팅하였다.

3.4 학습 전략

3.4.1 2단계 전이학습

1단계(백본 동결)는 최대 80 epoch, EarlyStopping(patience=20, val_loss 기준), 자체 정의한 OverfitControlCallback(20 epoch 이후부터 감시, train-val 정확도 격차 18%p · 손실 격차 0.20 초과 상태가 8회 연속 지속되면 조기 종료)을 적용하였다. 2단계(마지막 30개 레이어 미세조정)는 최대 200 epoch, EarlyStopping(patience=45), OverfitControlCallback(35 epoch 이후 감시, 격차 기준 16%p/0.18, 10회 연속 시 종료)을 적용하였고, 40 epoch 시점부터 Stochastic Weight Averaging(SWA)[17]을 병행하였다.

3.4.2 손실함수 및 최적화

본 연구가 사용한 Focal Loss[14]는 label smoothing이 적용된 정답 분포를 기준으로 계산된다. 클래스 수 K=3에 대해 원-핫 라벨 y를 다음과 같이 평활화한 뒤,

$$\hat{y_k} = y_k(1-\epsilon) + \frac{\epsilon}{K} \quad (K=3,\ \epsilon = \mathrm{label}_{\mathrm{smoothing}}) \qquad (2)$$

아래와 같이 손실을 산정한다(p_k는 소프트맥스 출력, γ는 focusing parameter):

$$\mathrm{FocalLoss}(y,p) = -\sum_{k=1}^{K} \hat{y_k}(1-p_k)^{\gamma}\log(p_k) \qquad (3)$$

γ=2.0으로 고정해 이미 잘 분류되는 샘플(p_k→1)의 기여도를 (1-p_k)^γ 항으로 자동 축소시키고, 상대적으로 어려운 샘플에 학습이 집중되도록 하였다. 이는 본 연구의 데이터셋이 클래스 간 불균형(양성 120/악성 561/정상 416)을 가지는 것과 맞물려, 오버샘플링만으로 완전히 해소되지 않는 클래스별 난이도 차이를 보완하는 역할을 한다.

학습률은 Cosine Annealing Warm Restart[18] 스케줄을 따랐으며, 에폭 t에서의 학습률은 다음과 같이 주기적으로 감소, 재시작된다:

$$\mathrm{lr}(t) = \mathrm{lr}_{\min} + \frac{1}{2}(\mathrm{lr}_{\max} - \mathrm{lr}_{\min})\left(1 + \cos\left(\pi \frac{T_{cur}}{T_i}\right)\right) \qquad (4)$$

여기서 T_cur는 현재 주기 내 경과 에폭 수, T_i는 i번째 주기의 길이이며, T_cur가 T_i에 도달할 때마다 T_cur를 0으로 재설정하고 T_i ← T_i × T_mult로 다음 주기를 확장한다. 1단계는 (lr_max, lr_min, T0, T_mult)=(1e-3, 1e-5, 5, 2), 2단계는 (1e-4, 1e-7, 10, 2)를 사용하였다. 이 warm-restart 구조는 학습률을 주기적으로 다시 끌어올려 국소 최적점에서 벗어날 기회를 제공하며, 40 epoch 시점부터 병행한 SWA(3.4.6절)와 결합되어 여러 국소해 주변의 가중치를 평균함으로써 일반화 성능을 개선하는 데 기여한 것으로 판단된다.

손실함수는 Focal Loss[14](γ=2.0, label smoothing=0.02)를 사용하였으며, 최적화기는 AdamW[13](1단계: lr_max=1e-3, lr_min=1e-5, T0=5, T_mult=2, weight decay=1e-4 / 2단계: lr_max=1e-4, lr_min=1e-7, T0=10, T_mult=2, weight decay=1e-4)를 사용하였다.

3.4.3 Mixup/CutMix 증강

1단계는 Mixup · CutMix를 각 α=0.3(적용확률 50:50)으로 상대적으로 강하게 적용하고, 2단계는 α=

0.1(CutMix 적용확률 30%)로 완화하여 미세조정 단계에서 과도한 증강 및 라벨 노이즈로 인한 성능 저하를 방지하였다.

Mixup[15]은 배치 내 두 샘플 (x_i,y_i), (x_j,y_j)을 혼합 비율 λ로 선형 결합한다:

$$\tilde{x} = \lambda x_i + (1-\lambda) x_j, \quad \tilde{y} = \lambda y_i + (1-\lambda) y_j$$
$$\lambda \sim B(\alpha, \alpha) \qquad (5)$$

CutMix[16]는 두 영상을 픽셀 단위로 섞는 대신, 한 영상의 사각형 영역을 다른 영상으로 잘라 붙이고(M은 잘라낼 영역이 1인 이진 마스크), 라벨은 그 영역이 차지하는 면적 비율로 혼합한다:

$$\tilde{x} = M \odot x_i + (1 - M) \odot x_j$$
$$\tilde{y} = \lambda y_i + (1-\lambda) y_j, \ \lambda = 1 - \frac{\text{area(M)}}{H \times W} \qquad (6)$$

두 기법 모두 $\lambda \sim$Beta(α,α)에서 샘플링되며, α이 클수록 λ가 0.5 부근에 몰려 더 강하게 섞이고 α이 작을수록 0 또는 1 근처로 치우쳐 원본에 가까운 샘플이 자주 생성된다. 1단계는 α=0.3, 2단계는 α=0.1을 적용하여 학습 단계별 증강 강도를 조절하였다.

3.4.4 7-Fold 교차검증

scikit-learn StratifiedKFold(n_splits=7, shuffle=True, random_state=42)로 오버샘플링된 학습 데이터를 7개 fold로 분할하고, fold마다 독립적으로 1·2단계 학습을 처음부터 수행하여 총 7개의 fold 모델을 생성하였다.

3.4.5 Test-Time Augmentation 및 Pseudo-labeling

각 fold 모델에 대해 테스트셋을 20회(TTA_STEPS=20) 반복 추론하였다(1회는 무변환, 나머지 19회는 좌우 반전·밝기 ±0.15×255·대비 0.85~1.15배를 무작위 적용) 후 평균하였고, 7개 fold의 TTA 평균 예측을 다시 평균하여 최종 앙상블 예측을 산출하였다. 이후 앙상블 예측 확신도(softmax 최댓값)가 0.88 이상인 테스트 샘플을 pseudo-label로 채택하여 오버샘플링된 학습 데이터에 합친 뒤, 별도 모델을 AdamW(lr=3e-5)로 15 epoch 추가 학습(Mixup α=0.1만 적용)하고, 이 모델의 TTA 예측을 기존 7-fold 앙상블에 추가로 합산하여 최종 정확도를 산출하였다.

fold k의 예측은 T=20회 TTA 추론(1회 무변환 + 19회 무작위 증강)의 평균으로 산출된다:

$$p_k = \frac{1}{T} \sum_{t=1}^{T} p_{k,t} \ \ (T = 20) \qquad (7)$$

7개(또는 Pseudo-labeling 모델이 추가된 8개) fold의 TTA 평균을 다시 단순 평균해 최종 앙상블 확률을 얻는다:

$$p_{final} = \frac{1}{K'} \sum_{k=1}^{K'} p_k \ \ (K' = 7 \text{ or } 8) \qquad (8)$$

Pseudo-label은 이 최종 앙상블 확률의 최댓값이 0.88 이상인 테스트 샘플에 한해 부여된다:

$$\widehat{y_{pseudo}} = \arg max(p_{final}) \ \text{ if } \ \max(p_{\text{final}}) \geq 0.88 \qquad (9)$$

3.4.6 Stochastic Weight Averaging(SWA)

2단계 학습의 40 epoch 시점부터 매 epoch 종료 시 가중치를 누적 평균하고 학습률을 1e-5로 고정하였으며, 학습 종료 시 누적 평균 가중치로 모델을 교체하여 손실 지형(loss landscape)의 넓고 평탄한 최적점을 지향하였다[17].

SWA[17]는 40 epoch 이후 매 epoch 종료 시점의 가중치 θ_n을 다음과 같이 누적 평균한다:

$$\theta_{SWA}^{(n)} = \frac{\theta_{SWA}^{(n-1)} \times (n-1) + \theta_n}{n} \ \equiv \ \frac{1}{N} \sum_{i=1}^{N} \theta_i \qquad (10)$$

좌변은 코드가 실제로 수행하는 온라인 갱신식

(새 가중치가 들어올 때마다 이전 평균과 새 값을 (n:1):1 비율로 재혼합)이며, 우변은 이 과정을 학습 종료 시점(n=N)까지 반복한 결과가 N개 가중치의 단순 평균과 같음을 보인 것이다. 학습 종료 후 모델 가중치를 θ_SWA로 교체함으로써, 하나의 국소 최적점이 아니라 여러 국소 최적점 주변을 평균한 더 평탄한(flat) 지점을 최종 모델로 채택하게 된다.

3.5 프라이버시 정량화 지표

3.5.1 SSIM·PSNR의 한계

단일 스케일 SSIM과 PSNR은 국소 윈도우 단위의 밝기·대비·구조 차이에 민감한 반면, Gaussian Blur처럼 저주파 성분(전역 밝기 분포)은 보존하면서 고주파 성분만 제거하는 변환에는 상대적으로 둔감하다는 한계가 있다. 이에 본 연구는 이 두 지표를 참고 지표로만 병기하고, 최종 프라이버시 점수 산정에는 사용하지 않았다.

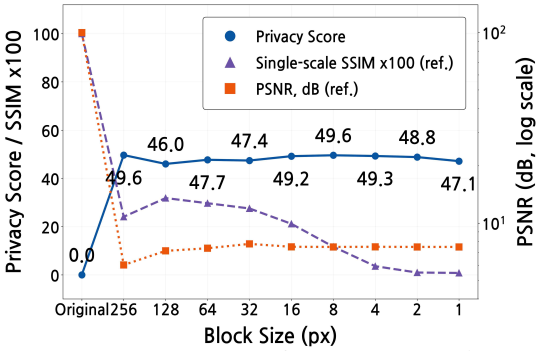


그림 1. Block Encryption 조건별 Privacy Score 및 참고 지표(Single-scale SSIM, PSNR) 비교

Fig. 1. Privacy Score with Reference Metrics (Single-scale SSIM, PSNR) across Block Encryption Conditions

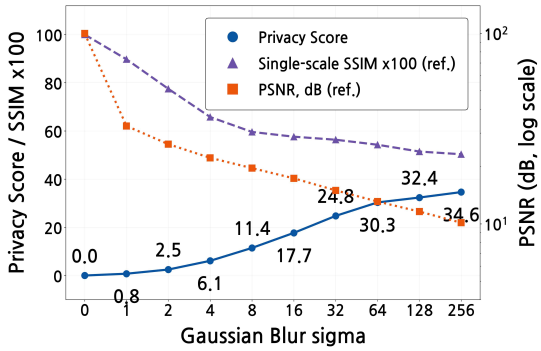


그림 2. Gaussian Blur 조건별 Privacy Score 및 참고 지표(Single-scale SSIM, PSNR) 비교

Fig. 2. Privacy Score with Reference Metrics (Single-scale SSIM, PSNR) across Gaussian Blur Conditions

PSNR(Peak Signal-to-Noise Ratio)은 원본 I와 변환 K 사이의 화소 오차를 데시벨(dB) 단위로 나타낸 지표로, 평균제곱오차(MSE) 기반으로 정의된다:

$$\mathrm{MSE} = \frac{1}{\mathrm{H} \times \mathrm{W}} \sum_{\mathrm{i,j}} (\mathrm{I(i,j)} - \mathrm{K(i,j)})^2$$

$$\mathrm{PSNR} = 10 \log_{10} \frac{255^2}{\mathrm{MSE}} \qquad (11)$$

MSE가 0(완전 동일)에 가까울수록 PSNR은 발산적으로 커지고(표에는 100dB로 상한 표기), 화소 차이가 클수록 PSNR은 낮아진다. PSNR은 화소 단위 오차만 반영해 사람의 지각적 유사성과 잘 맞지 않는 경우가 많고, 3.5.1절에서 지적한 대로 본 연구는 이를 참고 지표로만 표에 병기하고 Privacy Score 산정에는 반영하지 않았다.

3.5.2 MS-SSIM 기반 Privacy Score 정의

MS-SSIM은 두 영상 x, y에 대해 국소 윈도우 단위로 계산되는 세 가지 비교 성분인 휘도(luminance) l, 대비(contrast) c, 구조(structure) s를 기반으로 한다[4]:

$$l(x,y) = \frac{2\mu_x\mu_y + C_1}{\mu_x^2 + \mu_y^2 + C_1} \qquad (12)$$

$$c(x,y)=\frac{2\sigma_x\sigma_y+C_2}{\sigma_x^2+\sigma_y^2+C_2} \quad (13)$$

$$s(x,y)=\frac{\sigma_{xy}+C_3}{\sigma_x\sigma_y+C_3} \quad (14)$$

여기서 μx, μy는 각각 x, y의 국소 평균, σx, σy는 국소 표준편차, σxy는 국소 공분산이며, C1=$(0.01\times255)^2$, C2=$(0.03\times255)^2$ (C3=C2/2)는 분모가 0에 가까워질 때의 수치적 불안정성을 방지하기 위한 안정화 상수이다. 본 연구는 원본과 변환 영상을 각각 그레이스케일 휘도 채널(0.299R+0.587G+0.114B)로 변환한 뒤, 윈도우 크기 11의 균일(uniform) 필터로 각 성분을 계산하였다.

실제 계산 코드에서는 c(x,y)와 s(x,y)를 따로 구하지 않고, C3=C2/2를 대입해 대수적으로 정리한 결합형 cs(x,y)=c(x,y)×s(x,y)를 한 번에 계산한다. 이는 skimage 등 널리 쓰이는 SSIM 구현체의 표준 관행과 동일하며, 아래와 같이 정리된다:

$$\begin{aligned} cs(x,y) &= c(x,y)\times s(x,y) \\ &= \frac{2\sigma_x\sigma_y+C_2}{\sigma_x^2+\sigma_y^2+C_2}\times\frac{\sigma_{xy}+C_3}{\sigma_x\sigma_y+C_3} \\ &= \frac{2\sigma_x\sigma_y+C_2}{\sigma_x^2+\sigma_y^2+C_2}\times\frac{2\sigma_{xy}+C_2}{2\sigma_x\sigma_y+C_2} \\ &= \frac{2\sigma_{xy}+C_2}{\sigma_x^2+\sigma_y^2+C_2} \end{aligned} \quad (15)$$

즉 c(x,y)×s(x,y)의 (σxσy+C3) 항이 분자·분모에서 서로 상쇄되어, 스케일 j에서의 결합 성분은 다음과 같은 하나의 식으로 계산된다:

$$cs_{j(x,y)}=\frac{2\sigma_{xy}^{(j)}+C_2}{\sigma_x^{(j)2}+\sigma_y^{(j)2}+C_2} \quad (16)$$

이 cs_j(x,y)는 아래 MS-SSIM 결합식의 c_j(x,y)·s_j(x,y) 항과 수학적으로 완전히 동일한 값이다.

본 연구의 구현은 수식을 근사하거나 변형한 것이 아니라, 대수적으로 정리된 동일한 형태를 그대로 사용한 것이다.

단일 스케일 SSIM은 l·c·s 세 성분을 하나의 해상도에서만 결합하므로, Gaussian Blur처럼 국소 고주파 성분만 제거하고 전역 저주파 성분(밝기 분포)은 보존하는 변환에 상대적으로 둔감하다는 한계가 있다(3.5.1절). MS-SSIM은 이 한계를 보완하기 위해 원본 영상을 2×2 평균 풀링으로 반복 다운샘플링하여 j=1(원본 해상도)부터 j=M=5(가장 거친 해상도)까지 5단계의 해상도 피라미드를 구성하고, 각 스케일에서 c·s 성분을 계산한 뒤 가장 거친 스케일 M에서만 계산한 휘도 성분과 결합한다[4]:

$$\mathrm{MS-SSIM}(x,y)=[l_{M(x,y)}^{\alpha_M}]\prod_{j=1}^{M}[c_{j(x,y)}^{\beta_j}][s_{j(x,y)}^{\gamma_j}] \quad (17)$$

가중치 αM, βj, γj(j=1,…,5)는 Wang 등[4]이 인간 피험자의 주관적 화질 평가와의 상관관계를 최대화하도록 회귀로 추정한 값으로, 본 연구는 원 논문의 값을 βj=γj로 그대로 채택하였다.

표 1. MS-SSIM 스케일별 가중치
Table 1. Scale Weights for MS-SSIM

스케일 (j)	1	2	3	4	5 (=M)
가중치 (βj=γj, j=M일 때는 αM)	0.0448	0.2856	0.3001	0.2363	0.1333

거친 스케일(j가 5에 가까울수록)은 영상 전체의 형태·밝기 왜곡을, 세밀한 스케일(j가 1에 가까울수록)은 국소 경계·텍스처 왜곡을 각각 포착하므로, 여러 해상도의 곱으로 결합된 MS-SSIM은 단일 스케일 SSIM보다 인간의 지각적 화질 판단과 더 높은 상관관계를 갖는 것으로 보고되어 있다[4].

MS-SSIM은 두 영상이 완전히 동일할 때 1, 구조적으로 완전히 무관할 때 0에 가까운 값을 가지므로, 본 연구는 이를 프라이버시 관점의 비유사도(dissimilarity)로 재정의한 Privacy Score를 다음과 같이 산정하였다:

$$\mathrm{PrivacyScore}(x,y)=\frac{100\times(1-\mathrm{MS-SSIM}(x,y))}{2}$$

$$= 50 \times (1 - \mathrm{MS-SSIM}(x, y)) \qquad (18)$$

이는 SSIM 기반 거리 지표로 흔히 쓰이는 DSSIM = (1-SSIM)/2 형태(Wang 등[19])를

$$\mathrm{DSSIM}(x, y) = \frac{1 - \mathrm{SSIM}(x, y)}{2} \qquad (19)$$

MS-SSIM으로 확장하고 0~50 범위로 정규화한 것이다. 유사한 접근으로 Raynal 등[21]은 영상 난독화(obfuscation)의 프라이버시 수준을

$$d_{SSIM} = 1 - \mathrm{SSIM}(x, y) \qquad (20)$$

의 형태로 정량화한 바 있으며, 본 연구의 정의는 이를 다중스케일로 확장하고 (1-MS_SSIM)/2로 스케일을 조정한 것에 해당한다. MS-SSIM의 이론적 최댓값이 1이므로 Privacy Score의 이론적 상한은 50이며, 4.4절에서 확인되는 Block Encryption 조건들이 45~50점대에서 조기에 포화(saturate)되는 현상은 이 지표의 수학적 상한에 근접했기 때문으로 해석할 수 있다.

위 Privacy Score 식은 영상 한 장(x,y) 기준이다. 실제로는 조건 하나(예: Block256)마다 원본 1,097장 전체 각각에 대해 이미지별 Privacy Score를 구한 뒤 평균한다:

$$\mathrm{PrivacyScore}_i = 50 \times (1 - \mathrm{MS_SSIM}_i) \qquad (21)$$

$$\mathrm{PrivacyScore}_{condition} = \frac{1}{N} \sum_{i=1}^{N} \mathrm{PrivacyScore}_i \quad (N = 1{,}097) \qquad (22)$$

Privacy Score가 MS-SSIM에 대해 선형함수(50×(1-MS-SSIM))이므로, 이미지별 점수를 구한 뒤 평균하는 방식과 이미지별 MS-SSIM을 먼저 평균한 뒤 점수로 변환하는 방식은 수학적으로 동일한 값을 준다. 즉 산정 순서가 결과에 영향을 주지 않는다.

Privacy Score는 원본 1,097장 전체(512×512 리사이즈 기준)에 대해 조건별로 1회씩 계산되는 결정론적 지표로, 분류 모델의 학습·시드와 무관하게 항상 동일한 값을 갖는다.

3.5.3 프라이버시 보존 변환의 설계 원칙

본 연구는 프라이버시 보존 변환이 만족해야 할 핵심 조건으로 원상복구 불가능성(irreversibility)을 설정한다. 즉, 변환 영상 y로부터 원본 영상 x를 완전히 또는 유의미한 수준으로 복원할 수 있다면, 그 변환은 시각적으로 원본과 달라 보이더라도 프라이버시를 보호했다고 보기 어렵다. 이러한 관점은 Gaussian Blur가 딥러닝 기반 역복원(deblurring) 공격에 취약함을 보인 McPherson 등[6]의 결과와 부합한다.

Block Encryption에 대해서도 대칭적인 우려가 보고되어 있다. Chuman과 Kiya[23]는 블록·픽셀 셔플링 기반 암호화 영상에 지그소 퍼즐 solver(jigsaw puzzle solver) 공격을 적용해 시각 정보 대부분을 복원할 수 있음을 보였다. 이는 블록 재배열이 전역 구조(윤곽·형태)는 파괴하더라도, 인접했던 블록 간 경계·텍스처의 통계적 상관관계라는 국소 단서까지는 제거하지 못해, 이 상관관계를 활용하면 블록의 원래 배열을 상당 부분 재구성할 수 있기 때문이다. 즉 본 연구가 사용한 두 변환 기법 모두 딥러닝 기반 공격에 대한 이론적 원상복구 불가능성이 실증적으로 보장된 것은 아니며, 이는 본 연구가 3.5.2절에서 프라이버시 점수를 원본-변환 간 지각적·구조적 비유사도로 정의하면서도 5.3절에서 이를 복원 공격에 대한 안전성의 직접적 증거로 확대 해석하지 않도록 유의하는 이유이다.

다만 본 연구의 범위에서는 실제 역복원 공격 실험을 수행하지 않았으므로, 원상복구 불가능성은 본 연구가 실증적으로 검증한 결론이 아니라 프라이버시 보존 변환을 설계·평가하는 데 채택한 이론적 원칙이며, 이를 직접 검증하는 것은 6.2절에서 제시하는 향후 연구 과제로 위치시킨다.

3.6 실험 설계 및 평가지표

Block Encryption 10조건, Gaussian Blur 10조건, 두 기법의 조합 100조건을 합쳐 총 120개 비식별화 조건을 평가하였다. 각 조건은 exp_seed = 42 + ex

p_idx × 1000(exp_idx는 100-조합 목록 내 순번) 방식으로 조건별 고유 시드를 부여해 재현성을 확보하였다. 분류 성능 지표로는 (1) 7-Fold + Pseudo-labeling 앙상블・TTA 20회를 거친 테스트셋 Accuracy, (2) scikit-learn roc_auc_score(multi_class="ovr", average="macro") 기준 ROC-AUC, (3) 혼동행렬 대각성분 기준 클래스별 재현율(Recall, cm[i,i]/행합)을 사용하였고, 프라이버시 지표로는 3.5절의 MS-SSIM 기반 Privacy Score(0~50)를 사용하였다. 100개 조합의 학습은 계산 비용을 고려하여 단일 세션이 아닌 여러 세션에 걸쳐 조건 단위로 체크포인트・캐싱되었으며(조건별 exp_seed가 고정되어 있어 재학습 시에도 동일 결과가 재현됨), 이미 완료된 조건은 이후 세션에서 결과를 그대로 재사용하였다.

본 연구가 사용한 세 가지 분류 성능 지표는 다음과 같이 정의된다. 정확도(Accuracy)는 전체 테스트 샘플 N장 중 예측이 실제 라벨과 일치한 비율이다:

$$\mathrm{Accuracy} = \frac{1}{N}\sum_{i=1}^{N}\mathbf{1}[\hat{y_i} = y_i] \qquad (23)$$

클래스별 재현율(Recall)은 혼동행렬(confusion matrix) cm의 대각성분을 해당 행의 합으로 나눈 값으로, 실제 클래스 c인 표본 중 모델이 c로 옳게 예측한 비율을 의미한다:

$$\mathrm{Recall}_c = \frac{\mathrm{cm}_{c,c}}{\sum_{k=1}^{C}\mathrm{cm}_{c,k}} \quad (c=1,\cdots,C, C=3) \qquad (24)$$

ROC-AUC는 각 클래스를 나머지 전체와 구분하는 이진 분류 문제로 변환(One-vs-Rest)해 클래스별 AUC를 구한 뒤, 3개 클래스에 대해 단순 평균(macro)한 값이다:

$$\mathrm{ROC-AUC}_{\mathrm{macro}} = \frac{1}{C}\sum_{c=1}^{C}\mathrm{AUC}_c^{\mathrm{OvR}} \quad (C=3) \qquad (25)$$

본 연구는 3.6절에서 밝힌 바와 같이 Precision과 F1-score는 산출하지 않았으므로, 위 세 지표만을 분류 성능의 정의로 제시한다(5.3절의 한계 서술과 일관).

3.7 실험 환경

전체 실험은 NVIDIA GeForce RTX 4090(VRAM 24,564MiB) GPU 1기에서 TensorFlow 기반으로 수행되었으며, 연산 효율을 위해 혼합정밀도(mixed_float16) 학습을 사용하고 GPU 메모리는 동적 할당(memory growth)으로 운용하였다. 학습 중에는 5 epoch마다 GPU 사용률・온도・메모리 점유율을 모니터링하는 콜백을 두어 자원 병목을 상시 확인하였다.

IV. 실험 결과

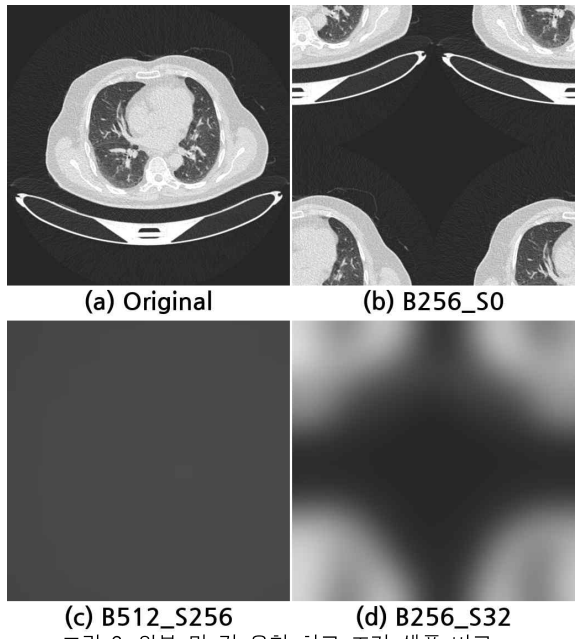


그림 3. 원본 및 각 유형 최고 조건 샘플 비교
Fig. 3. Comparison of Original and Optimal Samples for Each Method

그림 1은 본격적인 실험 결과 분석에 앞서, 원본 영상과 두 비식별화 기법이 확보할 수 있는 대표적 조건의 시각적 예시를 먼저 제시한 것이다. (a)는 비식별화가 적용되지 않은 원본 영상이며, (b)는 Block Encryption(블록 크기 256×256)만 단독 적용한 조건, (c)는 Gaussian Blur(σ=256)만 단독 적용한 조건, (d)는 두 기법을 조합(Block 256×256+σ=32)한 조건이다. 각 조건이 확보하는 정확도와 Privacy Sc

ore, 그리고 이 조건들을 최적으로 선정한 구체적 근거는 4.1~4.5절에서 순차적으로 제시한다.

4.1 Block Encryption 단독 적용 결과

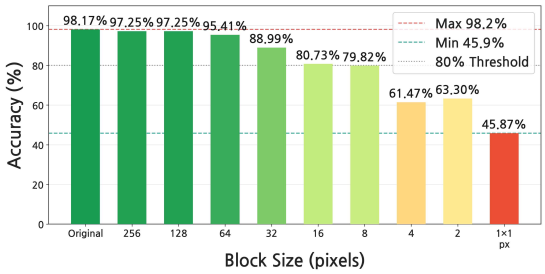


그림 4. 블록 크기에 따른 Block Encryption 단독 적용 시 정확도 변화

Fig. 4. Accuracy by Block Size for Block Encryption Alone

블록 크기가 256에서 8까지 줄어드는 동안에도 정확도는 97.25% → 79.82%로 완만하게만 하락하여, 상당히 넓은 구간에서 원본 대비 정확도 손실이 20%p 이내로 유지되었다. 다만 4×4 이하에서는 급격히 무너졌으며, 흥미롭게도 2×2(63.30%)가 4×4(61.47%)보다 오히려 높은 비단조적(non-monotonic) 구간이 관찰되었다. 이는 블록이 극단적으로 작아지면 재배열 패턴 자체가 국소 텍스처 통계를 일부 복원하는 효과와 관련된 것으로 추정되나(5.2절 참고), 조건당 1회 실험 결과이므로 확률적 변동 가능성도 배제할 수 없다.

4.2 Gaussian Blur 단독 적용 결과

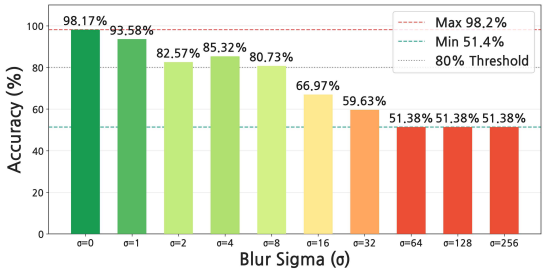


그림 5. Blur Sigma(σ)에 따른 Gaussian Blur 단독 적용 시 정확도 변화

Fig. 5. Accuracy by Blur Sigma (σ) for Gaussian Blur Alone

Blur는 σ=2 시점에 이미 정확도가 82.57%까지 떨어지고, σ=16에서 66.97%, σ=32에서는 59.63%로 붕괴 직전까지 도달한다. 10단계 중 같은 6번째 서수 위치를 기준으로 비교하면(Block 16×16 vs Blur σ=16), Block은 80.73%를 유지한 반면 Blur는 66.97%까지 떨어져, Block Encryption이 Gaussian Blur보다 정보 손실에 대해 더 완만한 성능 저하 특성을 보임을 본 실험에서 정량적으로 확인하였다.

4.3 Block+Blur 조합(100가지) 결과

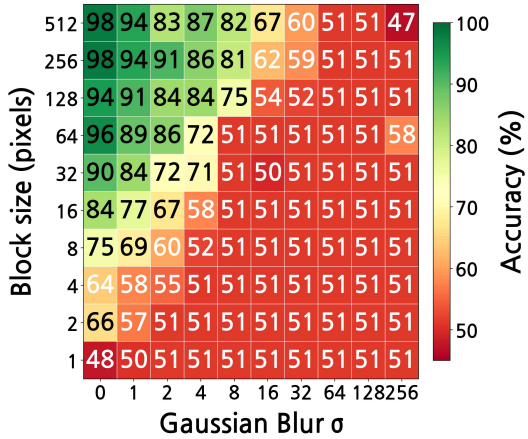


그림 6. Block Encryption과 Gaussian Blur 조합에 따른 정확도(%) 히트맵

Fig. 6. Accuracy (%) Heatmap of Block Encryption × Gaussian Blur Conditions

100개 조건 중 53개 조건이 정확히 51.38%(=56/109, 3.1.1절 참고)로 수렴하였다. 이는 테스트셋(109장) 중 최다 클래스인 Malignant(56장) 하나만 예측하는 다수 클래스 붕괴(majority-class collapse) 현상과 정확히 일치하며, 혼동행렬에서도 해당 조건들 모두 Malignant 재현율 98~100%·나머지 클래스 0%로 나타나 이를 뒷받침한다. 붕괴는 블록·블러 중 어느 한쪽이라도 정보 파괴 강도가 임계 이상이면 발생하며, 두 변환이 상호 가산적(additive)으로 작용함을 보여준다(예: Block256 단독은 σ=64에서야 붕괴하지만, Block32는 σ=8에서 이미 붕괴).

4.4 Privacy Score 분석

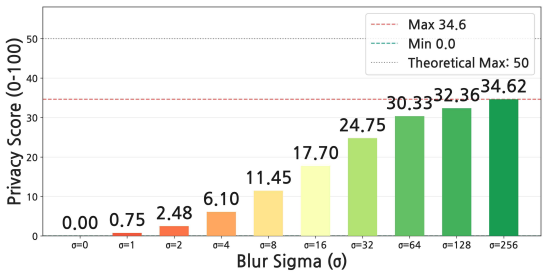


그림 7. 블록 크기에 따른 Privacy Score 변화
Fig. 7. Privacy Score by Block Size

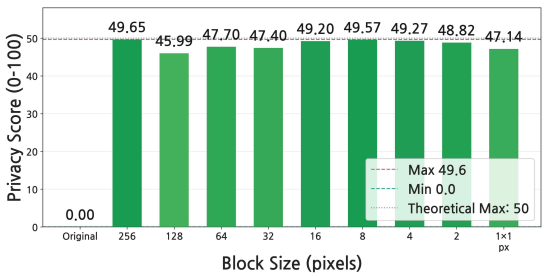


그림 8. Blur Sigma(σ)에 따른 Privacy Score 변화
Fig. 8. Privacy Score by Blur Sigma (σ)

가장 눈에 띄는 차이는 포화 속도다. Block Encryption은 블록을 256으로 한 번만 나눠도 Privacy Score가 49.65점으로 즉시 이론적 상한(≈50) 근처에 도달하고, 이후 블록 크기를 더 줄여도 45~50점 사이에서 정체(saturate)된다. 반면 Gaussian Blur는 σ=256까지 최대로 올려도 34.62점에 그쳐, 어떤 블러 강도로도 Block의 최저 수준(45.99점)조차 넘지 못한다.

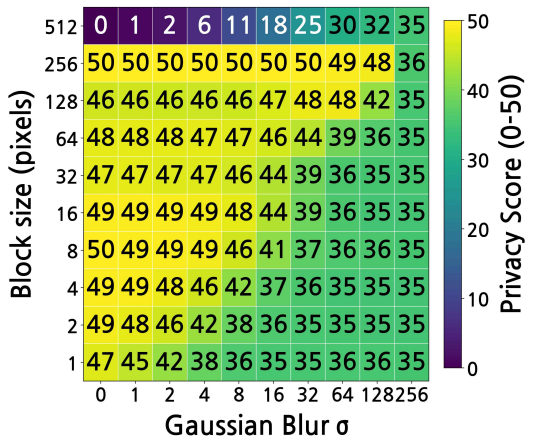


그림 9. Block Encryption과 Gaussian Blur 조합에 따른 Privacy Score 히트맵 (MS-SSIM 기반)
Fig. 9. MS-SSIM-Based Privacy Score Heatmap for Block Encryption × Gaussian Blur Conditions

블록 크기가 32 이하이면서 σ가 64 이상인 조합 전체(24개 조건)는 35.0~36.1점의 좁은 대역으로 수렴하는 포화 구간을 형성한다. 즉 이미 블록으로 충분히 파괴된 구조에 강한 블러를 추가로 씌워도 MS-SSIM 관점에서는 더 이상의 추가 프라이버시 이득이 거의 없다는 뜻이며, 이는 4.3절의 정확도 붕괴(51.38% 고정)와 정확히 같은 조건 구간에서 함께 나타난다. 정보가 임계 이상 파괴되면 정확도와 프라이버시 점수가 동시에 각자의 바닥/천장으로 수렴한다는 일관된 패턴이다.

4.5 정확도-프라이버시 트레이드오프 분석 (Pareto Frontier)

100개 조합 조건에 대해 다른 어떤 조건도 Privacy Score와 Accuracy를 동시에 능가하지 못하는 엄밀한 Pareto 최적점을 계산한 결과, 다음 3개 조건만이 Pareto frontier를 구성하였다.

표 2. Pareto-optimal 조건 (n=3)
Table 2. Pareto-Optimal Conditions (n=3)

Rank	Condition	Privacy Score	Accuracy	ROC-AUC
1	Block256+σ32	49.85	58.72%	0.7657
2	Block256+σ16	49.70	62.39%	0.8237
3	Block256+σ0	49.65	98.17%	0.9920

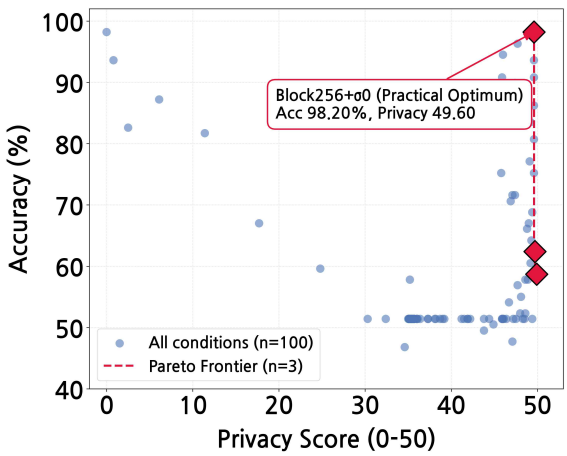


그림 10. Accuracy - Privacy Score 산점도 및 Pareto Frontier (n=100)
Fig 10. Accuracy - Privacy Score Scatter Plot and Pareto

Frontier (n=100)

수학적으로는 3개 지점 모두 Pareto-optimal이지만, 1·2위 조건은 3위 대비 Privacy Score를 0.05~0.20점 더 얻는 대가로 정확도를 35.5~39.5%p나 포기해야 한다. 실무적으로 의미 있는 트레이드오프가 아니다. Block256+원본(σ=0) 조건이 사실상 유일한 실질적 최적점이며, 이는 전체 120개 조건 중 최고 정확도(98.17%, 원본과 동률)와 이론적 상한에 근접한 Privacy Score(49.65/약 50)를 동시에 달성하는 지점이다.

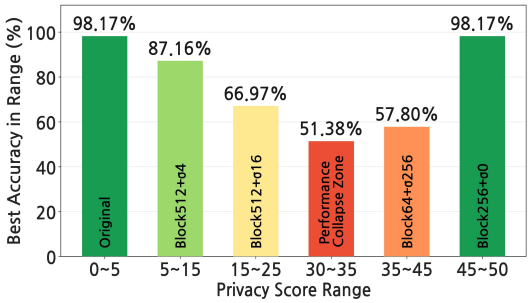


그림 11. Privacy Score 구간별 달성 가능한 최고 정확도

Fig. 11. Best Achievable Accuracy by Privacy Score Range

45~50점대(가장 높은 프라이버시 구간, 46개 조건 존재)에서 얻을 수 있는 정확도의 분산이 극단적으로 크다는 점이 핵심이다. 같은 높은 프라이버시 대역 안에서도 어떤 조건을 택하느냐에 따라 정확도가 48%~98%까지 벌어지며, Block 계열(특히 256)을 축으로 하고 Blur는 σ=0~8 수준으로만 보조적으로 쓰는 조합이 이 구간의 정확도를 지배한다.

V. 논 의

5.1 Block Encryption과 Gaussian Blur의 특성 비교

4.1~4.4절의 결과를 종합하면, 두 비식별화 기법은 단순히 정도의 차이가 아니라 작동 메커니즘 자체가 다르다는 점이 명확하게 드러난다. Gaussian Blur는 저역통과 필터로서 영상의 저주파 성분(전역 밝기·명암 분포)은 그대로 둔 채 고주파 성분(경계·미세 텍스처)만 제거한다. ResNet50과 같은 CNN은 초기 레이어에서 국소 경계·텍스처를 특징으로 추출하므로, 이 고주파 정보가 사라지면 진단에 필요한 병변 경계 정보도 함께 소실되어 σ=2 시점에 이미 정확도가 82.57%까지 급락한다(4.2절). 반면 Block Encryption은 픽셀 값 자체는 보존한 채 블록의 공간적 위치만 재배열한다. CNN의 합성곱 연산은 국소 이웃 픽셀 간의 공간적 상관관계에 의존하므로, 블록 내부(예: 256×256처럼 병변 크기보다 큰 블록)에서는 국소 구조가 온전히 보존되어 정확도 손실이 최소화되는 반면, 전역 형태 식별은 즉시 불가능해진다. 이 메커니즘 차이가 4.4절에서 확인한 것처럼 Block이 훨씬 적은 정확도 손실로 더 높은 MS-SSIM 기반 Privacy Score를 확보하는 근본 원인으로 판단된다.

McPherson 등[6]이 지적했듯 Blur는 저주파 정보가 보존되기 때문에 딥러닝 기반 역복원 공격에 취약한데, 본 연구의 결과는 이와 대칭적인 함의를 갖는다. 이 점은 5.3절에서 한계로 다시 다룬다.

5.2 정보손실 임계점과 모델 붕괴 현상

4.3절에서 확인한 51.38%(=56/109, Malignant 다수 클래스) 붕괴 지점은 완만한 연속적 저하가 아니라 임계값을 넘는 순간 급격히 발생하는 상 전이(phase-transition)적 양상에 가깝다. 이 수치는 추정이 아니라 3.1.1절에서 확인한 테스트셋 구성(전체 109장 중 Malignant 56장)에 정확히 대응하는 값으로, 100개 조합 중 53개 조건이 이 값에 정확히 수렴했다는 것은 모델이 정보가 임계 이하로 파괴된 입력에 대해 판단을 포기하고 최빈 클래스를 예측하는 퇴행적 전략으로 수렴함을 보여준다. 같은 임계 구간(블록 32 이하 × σ 64 이상)에서 Privacy Score 역시 35.0~36.1점의 좁은 대역으로 함께 수렴한다는 점(4.4절)은, 이 지점이 accuracy와 privacy score 두 지표 모두에서 더 이상 파괴할 유의미한 구조가 남아있지 않은 정보-이론적 바닥에 도달했음을 의미하는 것으로 해석된다.

한편 4.1절의 Block 2×2(63.30%) > 4×4(61.47%), 4.2절의 Blur σ=4(85.32%) > σ=2(82.57%)와 같은

비단조적(non-monotonic) 구간에 대해서는 해석에 신중할 필요가 있다. 본 연구는 조건별로 7-Fold 앙상블은 적용했으나, 조건 간 비교에는 조건별 1회의 실험(고유 시드)만 사용하였으므로, 이러한 역전 현상이 실제 신호인지 학습 과정의 확률적 변동(stochastic variance)인지 본 연구의 설계만으로는 완전히 구분하기 어렵다. 다만 4×4·2×2와 같이 매우 작은 블록에서는 재배열 후에도 국소 색상·질감의 전역 통계 분포(히스토그램) 자체는 원본과 유사하게 유지되므로, 극단적으로 작은 블록에서 오히려 일부 전역 통계 특징이 복원되는 효과가 실제로 존재할 가능성도 배제할 수 없다. 이는 후속 연구에서 조건당 다중 시드 반복 실험으로 검증이 필요한 가설로 남겨둔다. 한편 51.38%라는 붕괴 하한은 모든 정보파괴 조건에서 성립하는 것은 아니다. 전체 120개 조건 중 4개 조건(원본+σ256, Block32+σ16, Block1+원본, Block1+σ1)은 이 하한보다 낮은 정확도를 기록하였으며, 이들의 혼동행렬은 Malignant 재현율이 100%에 못 미치고 Normal 재현율도 0%가 아닌, 특정 클래스로 완전히 쏠리지 않은 패턴을 나타냈다. 특히 원본 해상도(512×512, Block Encryption 미적용)에 최대 강도(σ=256)의 Gaussian Blur만을 결합한 조건은 정확도 46.8%, ROC-AUC 0.5567로 무작위 수준에 근접해(Benign 0%·Malignant 82.1%·Normal 12.2%), 다수 클래스로의 퇴행적 수렴이 아니라 판별력 자체가 소실된 상태에 해당하는 것으로 판단된다. 이는 4.3절에서 제시한 다수 클래스 붕괴 메커니즘이 정보파괴가 극단적인 일부 조건에서는 완전히 들어맞지 않음을 보여준다.

5.3 임상적 적용 가능성 및 한계

4.5절의 분석 결과, Block 256×256 조건은 원본 영상과 동일한 98.17%의 정확도를 유지하면서 49.65의 Privacy Score를 확보하였다. 이는 비식별화에 따른 분류 성능 저하를 최소화하면서 개인정보 보호 수준을 동시에 확보할 수 있음을 의미하며, 의료기관 간 데이터 공유나 클라우드 기반 학습 환경과 같은 실제 의료 인공지능 적용 환경에서 활용 가능한 비식별화 조건으로 고려될 수 있다. 또한 학습 과정에서 기록된 조건별 fold-검증 정확도 로그를 분석한 결과, 개별 fold의 검증 정확도는 비식별화 조건과 관계없이 대체로 50~90% 범위에서 상당한 변동성을 나타냈다. 반면, 7개 fold의 예측 결과를 TTA 20회 및 Pseudo-labeling과 함께 앙상블하여 산출한 최종 테스트 정확도는 개별 fold의 검증 정확도보다 전반적으로 높게 나타났으며, 원본 조건에서 98.17%의 정확도를 기록하는 등 조건별 성능 역시 비교적 안정적인 경향을 보였다. 이는 5.2절에서 제시한 조건당 1회 실험의 한계를 직접적으로 해소하는 것은 아니지만, fold별 학습 과정에서 발생하는 성능 변동성이 앙상블을 통해 일정 부분 완화될 수 있음을 시사한다.

그러나 본 연구에는 몇 가지 한계가 존재한다. 먼저, 본 연구에서 사용한 Privacy Score는 원본 영상과 비식별화 영상 간의 구조적 유사도를 나타내는 MS-SSIM 기반 지표로, 실제 공격자가 딥러닝 기반 영상 복원 공격을 수행하는 상황에서의 재식별 저항성을 직접적으로 평가한 지표는 아니다. Chuman과 Kiya[23]의 연구에서 제시된 바와 같이 블록 스크램블링 기법 역시 특정 공격 모델에 대해서는 취약성을 나타낼 수 있으므로, 본 연구에서 도출된 높은 Privacy Score를 실제 공격 환경에서의 높은 보안성 또는 재식별 저항성과 동일한 의미로 해석하는 데에는 한계가 있다. 따라서 향후 연구에서는 딥러닝 기반 영상 복원 및 재식별 공격을 실제로 수행하여 다양한 공격 환경에서 비식별화 기법의 방어 성능을 검증할 필요가 있다. 또한 본 연구에서는 3.6절에서 기술한 바와 같이 Precision과 F1-score를 산출하지 않고 Recall, Accuracy 및 ROC-AUC를 중심으로 분류 성능을 평가하였다. 더불어 본 연구의 정확도 산출 과정에는 테스트셋에 대한 고확신도 예측 결과를 pseudo-label로 활용하여 재학습한 후 동일 테스트셋에서 성능을 재평가하는 transductive 절차가 포함되어 있다(3.4.5절). 이러한 평가 방식은 완전한 hold-out 방식에 비해 성능을 다소 낙관적으로 추정할 가능성이 있으므로, 본 연구의 절대적인 성능 수치보다는 동일한 평가 환경에서 비식별화 조건 간 상대적인 성능 차이를 중심으로 결과를 해석할 필요가 있다.

한편, 본 연구에서 사용한 IQ-OTH/NCCD 데이터셋은 110명의 환자로부터 2개 병원에서 수집된 1,097장의 영상으로 구성되어 있어 데이터셋의 규모와 대표성 측면에서 한계가 존재한다. 또한 특정 스캐너 장비 및 촬영 프로토콜을 기반으로 수집된 영상이라는 점에서, 다양한 의료기관과 서로 다른 영상 획득 장비 및 촬영 환경에서도 본 연구의 결과가 동일하게 유지되는지에 대한 일반화 가능성은 충분히 검증되지 않았다. 따라서 향후 연구에서는 다기관 및 다기종 데이터셋을 활용한 외부 검증을 수행하여 제안 방법의 일반화 성능을 추가적으로 평가할 필요가 있다. 마지막으로, 본 연구에서는 각 비식별화 조건에 대해 단일 학습 실험을 수행하였으므로, 조건 간 성능 차이에 대한 통계적 유의성을 충분히 검증하는 데에는 한계가 있다. 특히 5.2절에서 확인된 비단조적인 성능 변화는 학습 과정의 확률적 요인에 따라 동일 조건에서도 성능 차이가 발생할 가능성을 보여준다. 특히 5.2절에서 언급한 원본+σ256 조건은 독립적으로 수행된 Gaussian Blur 단독 실험(정확도 51.38%, ROC-AUC 0.4997)과 100-조합 실험 내 동일 조건(정확도 46.8%, ROC-AUC 0.5567) 간에 4%p 이상의 정확도 차이와 상이한 클래스별 예측 분포를 보였다. 두 실행 모두 ROC-AUC가 0.5 부근으로 사실상 무작위 수준의 판별력을 보인다는 점에서, 이 조건은 정보파괴로 모델의 판단 근거 자체가 소실되어 실행(시드)에 따라 결과가 크게 흔들리는 불안정 영역에 해당하는 것으로 해석된다. 반면 이에 대응하는 극단적 Block Encryption 조건(1×1 블록)은 단독실험과 조합실험 간 정확도 차이가 2%p 이내로 상대적으로 안정적이어서(5.1절 참고), 이러한 불안정성이 Gaussian Blur 계열 극단 조건에서 상대적으로 두드러지는 현상임을 시사한다. 다만 각 조건에 대해 7-Fold 교차검증과 TTA 기반 앙상블을 적용함으로써 단일 fold의 결과에 의존하는 것보다 상대적으로 안정적인 성능 추정이 가능하였다는 점에서 이러한 한계가 일부 완화될 수 있다. 향후에는 각 조건에 대한 반복 실험을 수행하고 평균과 표준편차 등의 통계적 지표를 함께 제시함으로써 비식별화 조건 간 성능 차이의 신뢰성과 통계적 유의성을 보다 엄밀하게 검증할 필요가 있다.

더 나아가, 본 연구의 Privacy Score가 반영하는 것은 어디까지나 원본과 변환 영상 간 화소·구조 수준의 통계적 비유사도이며, 실제 관찰자(제3자, 잠재적 공격자)가 변환 영상을 보고 얼마나 원본을 인식하거나 진단 정보를 유추할 수 있는지, 즉 지각적(perceptual) 관점의 프라이버시 보호 수준과는 별개의 문제이다. Sun 등[22]은 5개 데이터셋·14개 모델 아키텍처·4종의 재구성 공격(reconstruction attack) 기법에 걸쳐 사람이 직접 판단한 프라이버시 유출 여부를 수집해 비교한 결과, PSNR·SSIM·MSE·LPIPS 등 정형화된 지표가 인간의 판단과 약한 상관관계만을 보였음을 실증하였다. 특히 PSNR·SSIM 값이 더 높아 지표상으로는 원본과 더 유사하다고(즉 유출 위험이 더 크다고) 판단된 재구성 영상을 사람은 오히려 알아볼 수 없다고 평가하고, 반대로 지표상 유사도가 더 낮은 영상을 사람은 알아볼 수 있다고 평가하는 역전 사례까지 보고하였다. 이는 본 연구의 MS-SSIM 기반 Privacy Score 역시 "사람이 실제로 알아볼 수 있는가"를 직접 검증한 지표가 아니라 그에 대한 구조적 근사(proxy)임을 시사한다.

VI. 결론 및 향후 연구

6.1 결론

본 연구는 IQ-OTH/NCCD 폐암 CT 데이터셋에 Block Encryption과 Gaussian Blur를 단독 및 100가지 조합 형태로 적용하고, ResNet50 기반 분류 모델을 7-Fold 교차검증과 TTA 앙상블로 학습하여 총 120개 비식별화 조건의 분류 성능을 평가하였다. 또한 그동안 정성적으로만 서술되어 온 개인정보 보호 수준을 MS-SSIM 기반 Privacy Score로 정량화함으로써, 정확도와 프라이버시를 동시에 축으로 하는 트레이드오프 관계를 체계적으로 규명하였다. 주요 결과는 다음과 같이 요약된다.

첫째, Block Encryption은 블록 크기를 256×256으로 줄이는 것만으로도 Privacy Score 49.65점(이론적 상한 근접)을 확보하면서도 정확도 98.17%로 원

본과 동일한 수준을 유지하여, 두 목표를 동시에 만족하는 뚜렷한 스위트스팟을 형성하였다. 둘째, Gaussian Blur는 σ를 최대(256)까지 높여도 Privacy Score가 34.62점에 그쳐 Block Encryption의 최저 수준조차 넘지 못했으며, 정확도는 이보다 훨씬 빠르게 붕괴하였다. 셋째, 두 기법을 조합하면 정보 파괴 효과가 가산적으로 작용해, 블록·블러 중 어느 한쪽이라도 임계 강도를 넘으면 100개 조건 중 53개가 정확도 51.38%(다수 클래스 붕괴)로, 관련 24개 조건이 Privacy Score 35점대로 함께 수렴하는 포화 구간이 나타났다. 넷째, 100개 조건에 대한 Pareto 분석 결과 Block256×256+원본(무블러) 조건이 사실상 유일한 실질적 최적점으로 확인되었다.

이러한 결과는 Block Encryption이 Gaussian Blur보다 안정적인 프라이버시-정확도 트레이드오프 특성을 가진다는 점을, ResNet50 기반의 엄밀한 교차검증과 정량적 트레이드오프 곡선으로 규명하였다는 점에서 학술적·실무적 의의를 갖는다. 특히 Block256×256이라는 구체적이고 즉시 적용 가능한 조건을 제시함으로써, 의료영상 공유·클라우드 학습 파이프라인 설계에 실무적 지침을 제공할 수 있을 것으로 기대된다.

6.2 향후 연구 방향

본 연구의 결과를 바탕으로 향후 연구에서는 다음과 같은 방향으로 연구를 확장할 필요가 있다. 먼저, Block 256×256과 같은 저비용 비식별화 변환을 엣지 디바이스에서 수행한 후 변환된 영상만을 서버로 전송하여 추론하는 엣지-클라우드 기반 분산 추론 구조를 설계하고 그 실효성을 검증할 필요가 있다. 이러한 구조는 의료 영상이 원본 형태로 외부 서버에 전송되는 것을 최소화하면서도 추론 서비스를 제공할 수 있다는 점에서 실제 의료 환경에서의 개인정보 보호와 시스템 효율성을 동시에 고려할 수 있는 방안으로 활용될 수 있다. 또한 5.3절에서 제시한 한계를 보완하기 위해 Chuman과 Kiya[23], McPherson 등[6]의 연구에서 활용된 역복원 공격 모델과 유사한 실제 공격 시나리오를 Block 256×256 조건에 적용하여 비식별화 영상에 대한 복원 가능성과 재식별 저항성을 정량적으로 평가할 필요가 있다. 이를 통해 MS-SSIM 기반 Privacy Score만으로 평가하기 어려운 실제 공격 환경에서의 개인정보 보호 수준을 보다 직접적으로 검증할 수 있을 것으로 판단된다. 아울러 본 연구에서 확인된 Block 256×256의 성능 및 개인정보 보호 간 균형점이 특정 데이터셋에 한정된 결과인지 확인하기 위해, 서로 다른 의료기관과 영상 획득 장비 및 촬영 프로토콜을 기반으로 수집된 다기관·다기종 폐 CT 데이터셋을 활용한 외부 검증이 요구된다. 특히 다양한 데이터 분포에서도 동일한 조건이 최적의 비식별화 조건으로 유지되는지 검증함으로써 본 연구 결과의 일반화 가능성을 평가할 필요가 있다. 또한 5.2절에서 관찰된 비단조적인 성능 변화가 실제 비식별화 강도에 따른 현상인지 또는 학습 과정의 확률적 변동에 의해 발생한 결과인지를 구분하기 위해, 주요 비식별화 조건을 대상으로 다중 시드 기반 반복 학습을 수행하고 평균, 표준편차 및 신뢰구간 등의 통계적 지표를 함께 산출할 필요가 있다. 이를 통해 조건 간 성능 차이의 재현성과 통계적 유의성을 보다 엄밀하게 검증할 수 있을 것이다. 마지막으로, 본 연구에서 사용하지 않은 Precision, F1-score 및 완전한 혼동행렬을 추가적인 평가지표로 포함하여 분류 성능을 다각적으로 분석하고, Pseudo-labeling의 효과를 명확히 분리하기 위한 ablation study를 수행할 필요가 있다. 구체적으로는 Pseudo-labeling을 적용하지 않은 순수한 7-Fold 교차검증 및 TTA 기반 앙상블 결과와 Pseudo-labeling을 포함한 결과를 비교함으로써 해당 기법이 최종 성능 향상에 미치는 영향을 정량적으로 규명할 필요가 있다. 이러한 후속 연구를 통해 비식별화 수준과 분류 성능 간의 관계를 보다 체계적으로 규명하고, 실제 의료 환경에서 활용 가능한 개인정보 보호형 의료 영상 인공지능 시스템으로의 확장 가능성을 확보할 수 있을 것으로 기대된다.

또한 본 연구의 Privacy Score가 인간의 실제 지각 판단과 얼마나 부합하는지를 검증하기 위해, Sun 등[22]의 방법론을 참고하여 소수의 평가자에게 조건별 변환 영상을 제시하고 원본 식별 가능 여부 또는 병변 판독 가능 여부를 응답하게 하는 소규모

지각 평가(human perception study)를 수행하고, 그 응답과 본 연구의 Privacy Score 간의 상관관계를 분석하는 후속 연구가 필요하다.

References

[1] F. Bray et al., "Global cancer statistics 2022: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries," CA: A Cancer Journal for Clinicians, vol. 74, no. 3, pp. 229-263, 2024.

[2] K. He, X. Zhang, S. Ren and J. Sun, "Deep Residual Learning for Image Recognition," Proc. IEEE CVPR, pp. 770-778, 2016.

[3] D. A. Clunie et al., "Report of the Medical Image De-Identification (MIDI) Task Group – Best Practices and Recommendations," arXiv:2303.10473, 2023.

[4] Z. Wang, E. P. Simoncelli and A. C. Bovik, "Multiscale structural similarity for image quality assessment," Proc. IEEE Asilomar Conf. on Signals, Systems and Computers, vol. 2, pp. 1398-1402, 2003.

[5] R. Shokri and V. Shmatikov, "Privacy-preserving deep learning," Proc. 22nd ACM SIGSAC Conf. on Computer and Communications Security (CCS), pp. 1310-1321, 2015.

[6] R. McPherson, R. Shokri and V. Shmatikov, "Defeating Image Obfuscation with Deep Learning," arXiv:1609.00408, 2016.

[7] T. Chuman and H. Kiya, "Block Scrambling Image Encryption Used in Combination with Data Augmentation for Privacy-Preserving DNNs," arXiv:2104.01398, 2021.

[8] W. Sirichotedumrong, T. Chuman, S. Imaizumi and H. Kiya, "Grayscale-based block scrambling image encryption for social networking services," Proc. IEEE ICME, pp. 1-6, 2018.

[9] C. Dwork and A. Roth, "The Algorithmic Foundations of Differential Privacy," Foundations and Trends in Theoretical Computer Science, vol. 9, no. 3-4, pp. 211-407, 2014.

[10] M. Mohammadi, M. Vejdanihemmat, M. Lotfinia, M. Rusu, D. Truhn, A. Maier and S. Tayebi Arasteh, "Differential privacy for medical deep learning: methods, tradeoffs, and deployment implications," npj Digital Medicine, vol. 9, art. 93, 2026.

[11] H. F. Al-Yasriy, M. S. Al-Husieny, F. Y. Mohsen, E. A. Khalil and Z. S. Hassan, "Diagnosis of Lung Cancer Based on CT Scans Using CNN," IOP Conference Series: Materials Science and Engineering, vol. 928, 2020.

[12] A. R. Choudhury, J. Rautray, P. Mishra, M. Kandpal and S. S. Dalai, "Deep Learning Based Automated Lung Cancer Detection from CT scan Leveraging Transfer Learning," Procedia Computer Science, vol. 258, pp. 2748-2759, 2025.

[13] I. Loshchilov and F. Hutter, "Decoupled Weight Decay Regularization," Proc. ICLR, 2019.

[14] T.-Y. Lin, P. Goyal, R. Girshick, K. He and P. Dollár, "Focal Loss for Dense Object Detection," Proc. IEEE ICCV, pp. 2980-2988, 2017.

[15] H. Zhang, M. Cisse, Y. N. Dauphin and D. Lopez-Paz, "mixup: Beyond Empirical Risk Minimization," Proc. ICLR, 2018.

[16] S. Yun, D. Han, S. Chun, S. J. Oh, Y. Yoo and J. Choe, "CutMix: Regularization Strategy to Train Strong Classifiers with Localizable Features," Proc. IEEE ICCV, pp. 6023-6032, 2019.

[17] P. Izmailov, D. Podoprikhin, T. Garipov, D. Vetrov and A. G. Wilson, "Averaging Weights Leads to Wider Optima and Better Generalization," Proc. UAI, 2018.

[18] I. Loshchilov and F. Hutter, "SGDR: Stochastic Gradient Descent with Warm Restarts," Proc. ICLR, 2017.

[19] Z. Wang, A. C. Bovik, H. R. Sheikh and E. P. Simoncelli, "Image Quality Assessment: From Error Visibility to Structural Similarity," IEEE Transactions on Image Processing, vol. 13, no. 4, pp. 600-612, 2004.

[20] K. Packhäuser, S. Gündel, N. Münster, C. Syben,

V. Christlein and A. Maier, "Deep Learning-based Patient Re-identification Is able to Exploit the Biometric Nature of Medical Chest X-ray Data," Scientific Reports, vol. 12, art. 14851, 2022.

[21] M. Raynal, R. Achanta and M. Humbert, "Image Obfuscation for Privacy-Preserving Machine Learning," arXiv:2010.10139, 2020.

[22] X. Sun, N. Gazagnadou, V. Sharma, L. Lyu, H. Li and L. Zheng, "Privacy Assessment on Reconstructed Images: Are Existing Evaluation Metrics Faithful to Human Perception?," Advances in Neural Information Processing Systems (NeurIPS), vol. 36, 2023.

[23] T. Chuman and H. Kiya, "A Jigsaw Puzzle Solver-based Attack on Block-wise Image Encryption for Privacy-Preserving DNNs," arXiv:2211.02369, 2022.

저자소개

곽 윤 석 (Yunsuk Kwak)

2026년 경기대학교 학사

2026년 3월 ~ 현재 : 경기대학교 석사연구생

관심분야 : 인공지능, 컴퓨터 비전, 딥러닝, 의료영상 분석, 개인정보 보호

김 남 기 (Namgi Kim)

1997년 서강대학교 학사

2000년 KAIST 석사

2005년 KAIST 박사

2007년 ~ 현재 : 경기대학교 교수

관심분야 : 컴퓨터 네트워크, 이상 탐지, 추천시스템 최적화, 멀티캐스트 라우팅